

СРАВНИТЕЛЬНЫЙ АНАЛИЗ МЕТОДОВ ВИЗУАЛЬНОЙ ОДОМЕТРИИ НА ДАННЫХ АЭРОФОТОСЪЁМКИ ALTO

*Дьяков Андрей Николаевич
магистр, Томский государственный университет
систем управления и радиоэлектроники,
Россия, г. Томск*

Реферат

ВИЗУАЛЬНАЯ ОДОМЕТРИЯ, SIFT, ORB, SUPERPOINT,
LIGHTGLUE, ESSENTIAL MATRIX, ГОМОГРАФИЯ, DATASET ALTO

Объект исследования: визуальная одометрия, то есть оценка собственного движения по последовательности изображений.

Предмет исследования: три подхода к реализации визуальной одометрии и сравнение их точности, устойчивости и вычислительной стоимости.

Цель работы: реализовать три подхода к оценке собственного движения и установить, чем определяется точность каждого из них.

Методы исследования и аппаратура: детекторы ключевых точек SIFT, ORB и SuperPoint, сопоставление по дескрипторам, методом оптического потока Лукаса и Канаде и нейросетевым методом LightGlue. Восстановление движения выполнено через гомографию и через Essential Matrix. Расчёты проведены на языке Python с использованием библиотек OpenCV и PyTorch.

Полученные результаты и их новизна: установлено, что точность метода на отдельной паре кадров не определяет его точность на маршруте. Восстановление через Essential Matrix дало вдвое меньшую ошибку направления, чем гомография, однако его ошибка содержит постоянную составляющую и накапливается пропорционально пройденному пути, тогда как ошибка гомографии носит случайный характер и растёт медленнее.

Показатель роста ошибки составил от 1,17 до 1,20 у Essential Matrix против 0,74 и 0,81 у гомографии.

Результат воспроизведён на двух независимых маршрутах длиной 4,6 и 28,5 километра. Установлен предел точности, ниже которого не опускается ни один из подходов. Он составляет от 1,4 до 1,6 градуса и определяется покачиванием камеры вместе с носителем, а не качеством сопоставления кадров. Ни один из подходов не пригоден для самостоятельного определения положения на протяжённом маршруте.

Область применения: навигация беспилотных летательных аппаратов при недоступности спутникового сигнала, привязка аэрофотоснимков к местности, предварительная оценка движения в системах одновременного построения карты и определения положения на ней.

Направления дальнейшей работы: дополнение одометрии внешней привязкой, компенсация наклона камеры.

Оглавление

Введение.....	4
1 МАТЕМАТИЧЕСКИЕ ОСНОВЫ	6
1.1 Модель формирования изображения	6
1.2 Поиск и сопоставление ключевых точек.....	7
1.3 Гомография и Essential Matrix как модели движения между кадрами..	8
2 ПОСТАНОВКА ЭКСПЕРИМЕНТА	11
2.1 Оборудование и программное окружение.....	11
2.2 Датасет ALTO и происхождение выборок	12
2.3 Калибровка и физические константы	15
2.4 Выбор шага прореживания кадров.....	16
3 РЕЗУЛЬТАТЫ	18
3.1 Устойчивость ключевых точек (a)	18
3.2 Качество сопоставления (b)	20
3.3 Геометрический анализ (c).....	23
3.4 Накопление ошибки (d)	27
3.5 Нагрузка на устройство инференса (e)	32
4 ОБСУЖДЕНИЕ	35
4.1 Основные наблюдения	35
Заключение	36
Список используемых источников.....	37

Введение

Определение собственного положения является основой автономного полёта. Обычно эта задача решается спутниковой навигацией, однако сигнал может оказаться недоступен, от естественных помех до преднамеренного подавления. В таких условиях положение приходится определять по данным бортовых датчиков, и одним из них является камера.

Метод, восстанавливающий движение носителя по последовательности снимков, называется визуальной одометрией. Его идея проста. Если на двух соседних кадрах найти одни и те же участки местности и посмотреть, куда они сместились, можно понять, как переместилась сама камера. Складывая такие перемещения одно за другим, получают траекторию. Сложность в том, что каждый шаг определяется с ошибкой, а ошибки складываются. Поэтому основной вопрос при оценке метода визуальной одометрии состоит не в том, насколько точен отдельный шаг, а в том, как быстро накапливается ошибка.

Съёмка с воздуха вертикально вниз добавляет свои трудности. Местность с высоты выглядит почти плоской, перепад высот может быть мал по сравнению с высотой полёта, и часть геометрических методов в таких условиях работает неустойчиво. Кроме того, камера жёстко закреплена на носителе и покачивается вместе с ним.

Настоящая работа посвящена сравнению трёх подходов к визуальной одометрии. Первый отыскивает ключевые точки детекторами SIFT и ORB и сопоставляет их по дескрипторам, второй берёт те же детекторы, но прослеживает точки методом оптического потока, третий поручает и поиск, и сопоставление нейросетевой связке SuperPoint с LightGlue.

Интерес представляет не только точность каждого подхода на отдельной паре кадров, но и то, во что эта точность обращается на протяжённом маршруте. Целью работы является реализация трёх подходов и выяснение того, чем определяется точность каждого из них.

Для достижения поставленной цели определены следующие задачи:

1. реализовать три подхода к оценке собственного движения;
2. оценить устойчивость ключевых точек и влияние текстуры;
3. оценить качество сопоставления и влияние отбраковки ошибочных сопоставлений;
4. выполнить геометрический анализ восстановления движения;
5. измерить накопление ошибки вдоль маршрута и вычислительную нагрузку.

Настоящий отчёт состоит из четырёх разделов. Первый раздел излагает математические основы, необходимые для понимания дальнейшего изложения. Второй раздел описывает данные, оборудование и условия эксперимента. Третий раздел содержит результаты по пяти направлениям анализа. Четвёртый раздел объясняет полученные результаты и указывает на ограничения работы. Отчёт завершается заключением и списком использованных источников.

1 МАТЕМАТИЧЕСКИЕ ОСНОВЫ

1.1 Модель формирования изображения

Камера превращает точку местности в точку кадра. Простейшее описание этого превращения называется моделью камеры-обскуры [1]. В ней считается, что все лучи света проходят через одну точку, а изображение возникает на плоскости, отстоящей от неё на фокусное расстояние.

Пусть точка местности имеет координаты X , Y и Z в системе координат камеры, где ось Z направлена вдоль оптической оси. Тогда её положение на кадре в пикселях вычисляется по формулам

$$u = f \frac{X}{Z} + c_x, \quad v = f \frac{Y}{Z} + c_y,$$

где f обозначает фокусное расстояние, выраженное в пикселях, а c_x и c_y задают главную точку, то есть тот пиксель кадра, в который попадает направление оптической оси. Эти три числа записывают вместе в виде матрицы внутренних параметров камеры.

$$K = \begin{bmatrix} f & 0 & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

В формуле выше фокусное расстояние выражено в пикселях, тогда как в характеристиках объектива его указывают в миллиметрах. Это две записи одной и той же величины. Светочувствительная матрица камеры представляет собой сетку ячеек известного размера, и каждая такая ячейка даёт один пиксель кадра. Поэтому расстояние в миллиметрах переводится в число пикселей делением на размер одной ячейки:

$$f = \frac{F}{p},$$

где F есть фокусное расстояние объектива, а p есть размер ячейки матрицы, обе величины в миллиметрах.

Реальный объектив искажает изображение, из-за чего прямые линии на кадре слегка изгибаются. Это явление называется дисторсией и обычно

требует отдельной поправки. У использованной камеры дисторсия составляет 0,4 процента, что заметно меньше погрешности, с которой определяется положение ключевой точки. Поэтому далее дисторсия не учитывается, а камера считается идеальной.

Задача визуальной одометрии на паре кадров формулируется так. Даны два кадра, снятые из разных положений. Требуется найти поворот R и перемещение t камеры, произошедшие между съёмкой первого и второго кадра.

У этой задачи есть принципиальное ограничение, связанное с использованием одной камеры. Если всю снимаемую сцену увеличить в два раза и одновременно вдвое отодвинуть от неё камеру, оба кадра останутся точно такими же. Отсюда следует, что по двум кадрам можно определить направление перемещения, но не его длину. Длину приходится брать из постороннего источника, например из известной высоты полёта. Это свойство называется масштабной неопределённостью и далее играет заметную роль.

1.2 Поиск и сопоставление ключевых точек

Прежде чем восстанавливать движение, на кадрах нужно найти общие ориентиры. Для этого на каждом кадре отыскивают приметные места, например углы построек, перекрёстки дорог или края полей. Такие места называют ключевыми точками. Затем для каждой точки первого кадра отыскивают ту же самую точку на втором, и найденная пара называется сопоставлением.

Ключевые точки ищет детектор. Помимо самого положения точки он описывает её окрестность набором чисел, который называют дескриптором. Дескриптор нужен для того, чтобы точку можно было узнать на другом кадре, где она видна под иным углом и при ином освещении.

В работе сравниваются три детектора. SIFT [2] строит дескриптор по распределению перепадов яркости вокруг точки и устойчив к изменению

масштаба, но работает сравнительно медленно. ORB [3] описывает точку короче и грубее, зато считается в разы быстрее. SuperPoint [4] вместо заданных вручную правил использует обученную нейронную сеть, которая ищет точки и строит дескрипторы одновременно.

Сопоставление выполняется тремя способами. Первый сравнивает дескрипторы и для каждой точки первого кадра отыскивает точку второго с наиболее похожим описанием. Второй способ, оптический поток [5], дескрипторами не пользуется. Он прослеживает точку в небольшой окрестности прежнего положения, рассчитывая на то, что за один шаг она сместилась недалеко. Третий способ, LightGlue [6], представляет собой нейронную сеть. Она рассматривает точки обоих кадров разом и решает, что чему отвечает.

Детектор и способ сопоставления вместе образуют связку. Сравниваются пять связок, а именно SIFT с дескрипторами, ORB с дескрипторами, SIFT с оптическим потоком, ORB с оптическим потоком и SuperPoint с LightGlue.

1.3 Гомография и Essential Matrix как модели движения между кадрами

По готовому набору сопоставлений движение камеры восстанавливается одной из двух моделей. Обе отвечают на один и тот же вопрос, а именно куда сместились точки при переходе от первого кадра ко второму. Различаются они единственным предположением о форме снимаемой сцены, и из этого различия следует всё остальное.

Гомография предполагает, что все наблюдаемые точки лежат в одной плоскости. При таком условии переход от кадра к кадру описывается одной матрицей размера три на три, которая переносит любую точку первого кадра на её место во втором. Через движение камеры эта матрица выражается так:

$$H = K \left(R - \frac{t n^T}{d} \right) K^{-1},$$

где n есть нормаль плоскости, то есть направление, перпендикулярное поверхности земли, а d есть расстояние от камеры до этой плоскости.

Обратная операция называется разложением, она извлекает из матрицы искомое движение. Разложение H даёт поворот R , нормаль n и перемещение t , причём перемещение получается не в метрах, а в долях расстояния d . Если само расстояние известно, умножение на него переводит перемещение в метры. Так гомография обходит масштабную неопределённость, привлекая высоту полёта.

Essential Matrix не требует, чтобы сцена была плоской, и опирается на другое наблюдение. Точка, видимая на первом кадре, на втором обязательно лежит на некоторой прямой, положение которой полностью определяется движением камеры. Матрица E задаёт такую прямую для каждой точки и выражается через движение так:

$$E = [t]_{\times} R,$$

где запись $[t]_{\times}$ обозначает векторное произведение с вектором t , представленное в матричном виде.

Разложение E даёт поворот и направление перемещения, но не его длину. Причина видна при сравнении двух формул. У гомографии есть расстояние d , на которое можно умножить результат и получить метры. У Essential Matrix такого множителя нет, поскольку нет и самой плоскости, до которой его можно было бы измерить. Отказавшись от предположения о плоскости, модель теряет вместе с ним и привязку к метрам.

Платить за этот отказ приходится и требованиями к данным. Матрица E определяется по тому, насколько по-разному смещаются точки разной удалённости. Это различие называется параллаксом. Если все точки удалены одинаково, то есть сцена всё-таки плоская, либо если камера сместилась слишком мало, параллакса недостаточно и решение становится неустойчивым или не находится вовсе.

Ни одну из двух моделей нельзя вычислить по сопоставлениям напрямую, поскольку часть сопоставлений всегда оказывается ошибочной. Точка на втором кадре может быть найдена не та, особенно если местность содержит повторяющиеся детали. Даже небольшое число таких промахов способно испортить результат.

Для защиты от них применяется метод случайных выборок RANSAC [7]. Он берёт наугад несколько сопоставлений, строит по ним модель и считает, сколько остальных сопоставлений ей отвечает. Так повторяется много раз подряд, после чего выбирается та модель, которой отвечало наибольшее число сопоставлений. Уложившиеся в неё точки называют согласными, остальные отбрасывают как ошибочные.

Отвечает ли точка модели, решается по величине, которая называется невязкой. Модель предсказывает, где точка должна оказаться на втором кадре, а невязка показывает, насколько предсказание разошлось с наблюдением. Если невязка меньше заданного порога, точку считают согласной.

Для двух моделей невязка измеряет разное. Гомография предсказывает само положение точки, и невязкой служит расстояние до предсказанного места. Essential Matrix предсказывает не точку, а прямую, и невязкой служит расстояние от точки до этой прямой. Поскольку это величины разной природы, пороги для них задаются отдельно.

2 ПОСТАНОВКА ЭКСПЕРИМЕНТА

2.1 Оборудование и программное окружение

Все расчёты и замеры выполнены на одной персональной рабочей станции следующего состава:

- процессор AMD Ryzen 5 5600, шесть физических ядер и двенадцать логических потоков, базовая частота 3,5 ГГц;
- оперативная память объёмом 32 ГБ;
- видеокарта NVIDIA GeForce GTX 1660 SUPER с 6 ГБ видеопамяти;
- операционная система Windows 11 Pro 25H2 разрядностью 64 бита.

Программная часть написана на языке Python версии 3.11.9. Классические методы поиска и сопоставления ключевых точек взяты из библиотеки OpenCV версии 5.0.0 [8]. Нейросетевая связка выполнена средствами библиотеки PyTorch версии 2.13.0 с поддержкой CUDA [9], дополнительно использованы библиотеки torchvision версии 0.28.0, kornia версии 0.8.3 и эталонная реализация LightGlue из репозитория авторов. Обработка результатов выполнена библиотеками NumPy версии 2.4.6, pandas версии 3.0.5 и SciPy версии 1.17.1, построение графиков библиотекой Matplotlib версии 3.11.1.

Использованная видеокарта относится к поколению, в котором отсутствуют тензорные ядра, то есть вычислительные блоки, предназначенные специально для работы нейронных сетей. По этой причине нейросетевая связка работает на ней медленнее, чем работала бы на более современной видеокарте.

Кроме того, классические методы вычисляются на процессоре, используя все его потоки, тогда как нейросетевая связка вычисляется на видеокарте. Сравнивать их время напрямую нельзя, поскольку оно зависит не только от алгоритма, но и от устройства самой машины. Поэтому замеры выполнены в двух режимах, при всех доступных потоках процессора и при одном.

Метод случайных выборок из раздела 1.3 при каждом запуске даёт немного разный результат. Чтобы прогоны были повторяемыми, генератор случайных чисел зафиксирован.

2.2 Датасет ALTO и происхождение выборок

Исходными данными служит датасет ALTO [10], собранный исследовательской группой Университета Карнеги-Меллона. Использован комплект первого раунда соревнования General Place Recognition: Visual Terrain Relative Navigation, проходившего в рамках конференции ICRA 2022 [11]. Он охватывает перелёт длиной около 150 километров из штата Огайо в Питтсбург, выполненный в августе 2017 года камерой, направленной вертикально вниз, над застройкой, лесом, сельскохозяйственными угодьями и природным ландшафтом. Эталонные координаты получены системой NovAtel SPAN, объединяющей спутниковую и инерциальную навигацию, с точностью лучше одного метра.

Датасет создавался под задачу распознавания места, то есть поиска текущего кадра на заранее снятой карте, и включает спутниковые снимки той же местности 2012 года. Визуальная одометрия названа авторами лишь как одно из возможных применений, поэтому используется здесь вне первоначального замысла.

Каждому кадру сопоставлена строка телеметрии с координатами носителя в проекции UTM, высотой полёта и ориентацией в пространстве. Эти строки и образуют эталон, с которым сравнивается расчётная траектория. Колонки со временем нет, но съёмка велась с постоянной частотой 20 кадров в секунду, поэтому момент съёмки восстанавливается по номеру кадра. Сами кадры имеют размер 500 на 500 пикселей, примеры приведены на рисунке 2.1.



Рисунок 2.1 – Пример кадра маршрута

Данные разделены на три выборки, обозначенные *train*, *val* и *test*. Последняя поставляется без телеметрии, то есть без записанных координат носителя. Расчётную траекторию по такой выборке построить можно, но сравнить её не с чем, а значит, и судить о точности метода нельзя. По этой причине выборка *test* далее не рассматривается.

Названия двух оставшихся выборок в настоящей работе условны. Деление на обучающую и проверочную имеет смысл там, где что-то обучается, здесь же нейросетевая связка берётся в готовом виде, а классические методы обучения не требуют вовсе. Поэтому обе выборки равноправны и служат двумя независимыми маршрутами. Характеристики выборок приведены в таблице 2.1.

Таблица 2.1 – Характеристики использованных выборок

Характеристика	train	val
Число кадров	10 436	1 684
Длина маршрута, м	28 511	4 592
Расстояние между соседними кадрами, м	2,74	2,81
Диапазон высот, м	437–548	376–455
Извилистость маршрута, град	136,8	22,0
Насыщенность кадра деталями	0,15	0,28

Извилистость показывает, насколько маршрут отклоняется от прямой линии. Через каждые 25 метров пути измеряется направление полёта, после чего все его изменения складываются без учёта знака. Прямой маршрут даёт ноль, петляющий даёт большое значение.

Приведённые в таблице числа сравнивать напрямую нельзя, поскольку маршруты различаются по длине более чем в шесть раз. В пересчёте на километр пути обе выборки дают 4,8 градуса, то есть вертолёт летит почти по прямой. Это затрудняет проверку восстановления поворота носителя, поскольку при отсутствии поворотов расчётное значение не с чем сравнивать. Подробнее об этом в разделе 3.3.

Насыщенность кадра деталями вычисляется как медиана перепадов яркости между соседними пикселями. Однородное поле даёт низкое значение, лесной массив высокое. Выборка val почти вдвое превосходит train, поскольку значительная её часть проходит над лесом.

2.3 Калибровка и физические константы

Чтобы применить модель из раздела 1.1, нужно знать фокусное расстояние камеры и её главную точку. Кроме того, движение восстанавливается в осях камеры, а эталон записан в осях, связанных с землёй, поэтому перед сравнением одно переводится в другое. Все эти величины получены отдельной процедурой калибровки, выполненной до основных расчётов на выборке из 150 пар кадров каждого маршрута.

Фокусное расстояние объектива равно 3,5 мм, размер ячейки матрицы 0,0045 мм. По формуле из раздела 1.1 это даёт 778 пикселей. За главную точку взят центр кадра.

Полученное значение проверено измерением по самим кадрам. Телеметрия говорит, на сколько метров сместился вертолёт между двумя снимками, а кадры показывают, на сколько пикселей при этом сместилась картинка. Разделив одно на другое, получают, сколько метров земли приходится на один пиксель, а деление высоты полёта на эту величину даёт фокусное расстояние. Измерение дало 847 пикселей на маршруте train и 724 пикселя на маршруте val.

Два маршрута расходятся между собой на 16 процентов, что больше их расхождения с расчётными 778 пикселями, составляющего от 7 до 9 процентов. Принять измеренные значения означало бы задать разное фокусное расстояние для двух маршрутов, тогда как камера в обоих случаях одна и та же. Поэтому в расчётах принимается единое значение 778 пикселей.

Камера установлена на носителе под некоторым углом, поэтому направление, которое она считает движением вперёд, не совпадает с направлением, записанным в телеметрии. Этот угол измерен так: по многим парам кадров вычислено направление движения и подобран поворот, который лучше всего совмещает расчётные направления с эталонными. Он составил 10,10 градуса, причём оценки на двух маршрутах разошлись всего на 0,73 градуса.

Совмещение при этом вышло неполным. Даже после наилучшего поворота расчётные направления расходятся с эталонными, и на кадрах, отобранных по наименьшему наклону камеры, это расхождение составило от 1,4 до 1,6 градуса.

Это и есть предел точности. Камера жёстко закреплена на носителе и покачивается вместе с ним, а наклон камеры смещает изображение почти так же, как её перемещение. По одной паре кадров эти два движения неразличимы, поэтому ни один из методов не определит направление движения точнее полутора градусов, как бы хорошо он ни сопоставлял точки.

Наконец, гомографии нужна высота полёта, чтобы переводить перемещение в метры. Описание датасета говорит, что в телеметрии записана высота над землёй, и калибровка с этим согласуется. Будь высота отсчитана от уровня моря, измеренное фокусное расстояние разошлось бы с расчётным в два или три раза, тогда как на деле оно расходится не более чем на 9 процентов.

2.4 Выбор шага прореживания кадров

Соседние кадры сняты с промежутком 2,8 метра, и картинка за один кадр сдвигается всего на четыре или пять пикселей. Такого смещения слишком мало, поэтому пары составляются через некоторое число кадров, и это число требуется выбрать. Снизу его ограничивает Essential Matrix, которой при малом смещении не хватает параллакса (раздел 1.3). Сверху ограничение накладывает оптический поток, то есть способ сопоставления, при котором точку не разыскивают по всему второму кадру, а прослеживают в небольшой окрестности прежнего положения. Ушедшая за пределы этой окрестности точка теряется.

Шаг подобран перебором значений от 1 до 50 на трёх участках маршрута val длиной 300, 600 и 900 кадров. Для каждого значения измерена ошибка направления движения по всем пяти связкам и обеим геометриям.

Пригодным считался шаг, при котором отрабатывают все связки на всех участках, а из пригодных выбран наименьший.

Этому условию отвечают шаги 12 и 20, и принят шаг 12. Ему соответствует расстояние 34 метра между кадрами пары и смещение картинки около 54 пикселей, то есть примерно десятая часть кадра. Зависимость ошибки от шага приведена на рисунке 2.2.




Рисунок 2.2 – Ошибка направления движения при разных шагах прореживания

Единый шаг для всех связок и обеих геометрий выбран ради сопоставимости результатов, но оптимальным для каждой из них он не является. Гомография даёт наименьшую ошибку при шаге от 8 до 12, тогда как Essential Matrix при шаге от 20 до 30.

3 РЕЗУЛЬТАТЫ

3.1 Устойчивость ключевых точек (а)

Работа любой из связок начинается с детектора, и от него зависит всё последующее. Никакая модель не восстановит движение, если на двух кадрах не нашлось одних и тех же точек. Если детектор отметил на первом кадре угол дома, а на втором тот же угол пропустил, точка выпадает из работы, и сопоставлять становится нечего.

Повторяемость измеряется так. Точки первого кадра переносятся на второй по заранее известному соответствию между кадрами. Если рядом с перенесённым местом детектор самостоятельно нашёл точку, она засчитывается как повторившаяся. Доля таких точек и есть повторяемость. Результаты измерения приведены в таблице 3.1.

Таблица 3.1 – Повторяемость ключевых точек

Детектор	Повторяемость, %		Случайные совпадения, %	
	train	val	train	val
SIFT	71,6	69,4	13,2	18,6
ORB	81,9	80,0	16,8	18,6
SuperPoint	71,2	66,7	18,6	18,6

Порядок детекторов одинаков на обоих маршрутах. Впереди ORB с результатом около 80 процентов, SIFT и SuperPoint идут вровень и уступают ему примерно десять процентов.

Вторая колонка нужна для того, чтобы эти числа не переоценить. Точек на кадре много, и рядом с перенесённым местом какая-нибудь точка может оказаться просто по совпадению, безо всякой связи с исходной. Такие случайные попадания дают от 13 до 19 процентов, и на эту величину повторяемость завышена у всех детекторов одинаково.

Насыщенность кадра деталями влияет на повторяемость положительно у всех трёх детекторов. На маршруте train связь составляет от 0,21 до 0,35, на val от 0,18 до 0,29, то есть на кадрах, богатых текстурой, точки ставятся устойчивее. Связь слабая, и на рисунке 3.1 видно, почему: разброс внутри одного и того же уровня насыщенности превышает разницу между её крайними значениями.




Рисунок 3.1 – Повторяемость точек в зависимости от насыщенности кадра деталями, выборка val

Повторяемость, таким образом, ставит ORB впереди двух других детекторов примерно на десять процентов, и результат этот устойчив, поскольку получен на обоих маршрутах. Стоит, однако, помнить, что именно она измеряет. Повторяемость говорит о том, насколько надёжно детектор находит отдельную точку, но ничего не говорит о том, где на кадре эти точки оказываются, а для восстановления движения второе не менее важно.

3.2 Качество сопоставления (b)

Часть найденных сопоставлений всегда оказывается ошибочной, и отбраковка, описанная в разделе 1.3, отделяет верные от неверных. Долю уцелевших после отбраковки называют долей согласных точек, и она служит первой мерой качества сопоставления. Результаты приведены в таблице 3.2.

Таблица 3.2 – Доля согласных точек

Связка	Геометрия	Доля согласных, %		Худшие пары, %	
		train	val	train	val
SIFT + дескрипторы	Гомография	89,2	84,8	67,2	69,5
	Essential Matrix	89,8	92,9	1,1	71,5
ORB + дескрипторы	Гомография	91,5	86,6	75,4	72,9
	Essential Matrix	60,8	78,1	1,5	4,8
SIFT + оптический поток	Гомография	90,7	82,1	55,6	61,4
	Essential Matrix	92,4	95,2	0,0	22,9
ORB + оптический поток	Гомография	93,6	89,9	67,8	59,1
	Essential Matrix	92,1	95,3	0,7	15,9
SuperPoint + LightGlue	Гомография	81,4	73,5	62,9	60,4
	Essential Matrix	79,6	81,2	6,3	64,5

Доля согласных точек высока у обеих моделей и в большинстве случаев превышает 80 процентов. Заметно выпадает лишь ORB с дескрипторами при работе через Essential Matrix, где она опускается до 60,8 процента на выборке train.

Основное различие между моделями обнаруживается не в среднем значении, а в поведении на трудных парах. Для этого в таблице приведена та же доля, посчитанная по 10 процентам самых неудачных пар, поскольку среднее провалы скрывает. У гомографии и там сохраняется от 55 до 75 процентов сопоставлений. У Essential Matrix та же величина падает почти до нуля на выборке train у всех связок и до единиц процентов у части связок выборки val. Иными словами, у гомографии качество ухудшается плавно, а у Essential Matrix на части пар модель не строится вовсе, и среднее значение это скрывает.

Высокая доля согласных точек, однако, ещё не означает верно найденного движения. Точки способны дружно уложиться в неверную модель, и тогда доля окажется высокой при неверно определённом движении.

Было бы удобно, если бы доля согласных точек сама по себе служила признаком качества. Тогда о верности найденного движения можно было бы судить прямо в полёте, где эталона нет. Проверить такую возможность позволяет связь между долей согласных точек и ошибкой направления. Полная связь дала бы -1 , полное её отсутствие ноль.

У гомографии связь составила $-0,07$ на обеих выборках, то есть доля согласных точек о качестве результата не сообщает ничего. У Essential Matrix получилось от $-0,45$ до $-0,54$, связь заметна, но для самостоятельной оценки её недостаточно.

Влияет на результат и порог невязки, то есть допуск, при котором точка ещё считается согласной. Зависимость показана на рисунке 3.2.




Рисунок 3.2 – Влияние порога невязки на долю согласных точек и ошибку направления, выборка val

У гомографии ошибка направления держится около 15 градусов при любом пороге. У Essential Matrix она меняется в разы, составляя 3,9 градуса при самом строгом пороге и доходя до 51,7 при отключённой отбраковке. На выборке train наблюдается то же самое.

Доля согласных точек у Essential Matrix ведёт себя при этом немонотонно и на пороге 5 пикселей проваливается, хотя с расширением порога должна только расти. Провал воспроизводится на обеих выборках.

Отбраковка, таким образом, нужна прежде всего Essential Matrix. Причина в разной величине собственной ошибки. У гомографии она велика, и ошибочные сопоставления на её фоне почти не заметны. У Essential Matrix собственная ошибка мала, поэтому именно промахи определяют итог.

Способ поиска согласного набора точек также влияет на результат. Помимо RANSAC опробованы три его позднейших развития, результаты приведены в таблице 3.3.

Таблица 3.3 – Ошибка направления движения при разных способах отбраковки, град

Способ	Гомография		Essential Matrix	
	train	val	train	val
RANSAC	20,1	15,2	11,2	6,1
LMEDS	19,9	13,3	9,4	3,6
USAC_DEFAULT	18,6	13,6	7,2	2,8
USAC_MAGSAC	16,8	13,7	6,9	2,8

Классический RANSAC уступает всем трём на обеих выборках, причём для Essential Matrix разница доходит до двух раз, а для гомографии не превышает пятой части. Метод LMEDS при этом оказался медленнее остальных примерно в семь раз, тогда как USAC_MAGSAC [12] не уступает RANSAC по времени. Все последующие расчёты выполнены с RANSAC.

3.3 Геометрический анализ (с)

Предыдущие разделы брали ошибку направления движения целиком. Между тем она складывается из двух частей, которые ведут себя совершенно по-разному.

Первая часть постоянна и направлена всегда в одну сторону, её называют уводом. Вторая меняется от пары к паре без всякой системы, её называют разбросом. Различать их важно потому, что на длинном маршруте увод накапливается, а разброс во многом гасит сам себя. Результаты разложения приведены в таблице 3.4.

Таблица 3.4 – Разложение ошибки направления движения, град

Связка	Геометрия	Ошибка		Увод		Разброс	
		train	val	train	val	train	val
SIFT + дескрипторы	Гомография	18,0	14,8	≈ 0	≈ 0	18,0	14,8
	Essential Matrix	10,3	5,3	1,4	1,3	10,3	5,7
ORB + дескрипторы	Гомография	20,4	20,2	≈ 0	≈ 0	20,4	20,6
	Essential Matrix	20,6	9,8	≈ 0	5,5	20,3	11,0
SIFT + оптический поток	Гомография	19,4	17,7	≈ 0	-5,2	19,5	19,2
	Essential Matrix	9,6	5,3	1,2	1,4	9,6	5,7
ORB + оптический поток	Гомография	22,3	24,7	≈ 0	-8,8	22,3	23,1
	Essential Matrix	13,1	8,3	2,2	2,0	12,6	7,4
SuperPoint + LightGlue	Гомография	16,9	13,7	≈ 0	≈ 0	16,7	13,7
	Essential Matrix	9,0	6,5	1,1	≈ 0	8,9	6,5

Знаком ≈ 0 отмечен увод, неотличимый от нуля по величине собственной погрешности.

На отдельной паре кадров Essential Matrix точнее гомографии примерно вдвое. Ошибка первой лежит в пределах от 5,3 до 20,6 градуса, второй от 13,7 до 24,7 градуса, и порядок этот выдерживается почти на всех связках обеих выборок.

Худшими же оказываются обе связки с ORB, хотя по повторяемости он был первым. Его точки устойчивы, но собраны кучно. Охват кадра, то есть доля площади, покрытая сопоставленными точками, составляет у ORB от 41 до 48 процентов против 82 у SuperPoint, а модель, построенная по кучным точкам, в остальной части кадра расходится с наблюдениями.

Различаются модели и устройством своей ошибки. У гомографии увод отсутствует в большинстве случаев, а вся ошибка приходится на разброс. У Essential Matrix увод есть у четырёх связок из пяти на обеих выборках и составляет от одного до двух градусов. Различие видно и на рисунке 3.3, где распределение ошибки Essential Matrix заметно смещено от нуля, тогда как у гомографии оно шире, но расположено симметрично.




Рисунок 3.3 – Распределение ошибки направления движения, выборка val

Отдельно стоит отметить, что на части пар Essential Matrix указывает направление, обратное истинному. Такие развороты составляют 8,8 процента пар на выборке val и 12,3 процента на train, тогда как у гомографии их 0,7 и 2,9 процента. В приведённую ошибку развороты почти не попадают, поскольку она считается по медиане, а медиана редких выбросов не замечает, но на траектории сказываются сильнее любой неточности.

Поворот носителя восстановить не удалось ни одним из способов. За один шаг вертолёт поворачивается на 0,76 градуса на выборке val и на 0,79 градуса на train, тогда как ошибка оценки поворота составляет от 1,1 до 3,3 градуса. Сигнал оказывается в два и более раза слабее шума, что видно на рисунке 3.4, где все столбцы лежат выше отметки истинного поворота.




Рисунок 3.4 – Ошибка восстановления поворота за шаг, выборка val

Гомография, в отличие от Essential Matrix, даёт длину перемещения в метрах, поэтому её можно сравнить с эталонной. На выборке val лучшие связки справляются с этим хорошо. SIFT с дескрипторами завышает длину пути на 2,4 процента, SuperPoint с LightGlue занижает на 4,6 процента. На выборке train обе связки завышают, на 14,1 и 10,1 процента соответственно. Связки с оптическим потоком метрической точности не дают вовсе, ошибаясь в длине пути более чем в полтора раза.

3.4 Накопление ошибки (d)

Траектория складывается из отдельных перемещений, и ошибки этих перемещений накапливаются. Насколько далеко расчётный путь уходит от истинного, показывает дрейф, то есть расхождение в конечной точке, выраженное в долях пройденного пути. Результаты приведены в таблице 3.5.

Таблица 3.5 – Накопление ошибки вдоль маршрута

Связка	Геометрия	Дрейф, %		Показатель роста	
		train	val	train	val
SIFT + дескрипторы	Гомография	41,3	16,9	0,72	0,92
	Essential Matrix	43,6	14,2	1,19	1,20
ORB + дескрипторы	Гомография	27,2	4,1	0,72	0,56
	Essential Matrix	34,0	18,9	0,94	1,13
SIFT + оптический поток	Гомография	33,7	7,2	0,75	0,81
	Essential Matrix	44,1	9,1	1,17	1,24
ORB + оптический поток	Гомография	36,0	50,4	0,76	0,79
	Essential Matrix	52,9	14,8	1,10	1,03
SuperPoint + LightGlue	Гомография	42,8	17,2	0,74	0,89
	Essential Matrix	38,2	14,0	1,21	1,20

На отдельной паре кадров Essential Matrix была точнее гомографии вдвое, а на траектории её преимущество на коротком маршруте val едва различимо и на длинном маршруте train сменяется отставанием.

Объясняет это показатель роста ошибки. Он сравнивает, насколько быстро растёт ошибка с тем, насколько быстро удлиняется путь. Значение около единицы означает, что удвоение пути удваивает и ошибку. Значение около половины означает, что ошибка вырастает лишь в полтора раза, поскольку промахи отдельных шагов частично гасят друг друга.

У Essential Matrix показатель близок к единице, 1,17 и 1,20 на двух выборках, у гомографии он заметно ниже, 0,74 и 0,81. Так и должно быть по разложению из раздела 3.3. Увод Essential Matrix направлен всегда в одну сторону, поэтому шаги складываются, а разброс гомографии направления не имеет. Зависимость расхождения от длины отрезка пути показана на рисунке 3.5.




Рисунок 3.5 – Рост расхождения с эталонной траекторией по мере удлинения пути, выборка val

Свою роль играют и отмеченные выше развороты. Одна пара, на которой оценка указала назад, смещает всю последующую траекторию, и восьми процентов таких пар достаточно, чтобы преимущество в точности отдельного шага сошло на нет.

Вид самих траекторий приведён на рисунках 3.6–3.9. На коротком маршруте val кривые, восстановленные через Essential Matrix, держатся ближе друг к другу, тогда как у гомографии одна из связок, ORB с оптическим потоком, уходит далеко в сторону и даёт дрейф 50,4 процента.




Рисунок 3.6 – Траектории, восстановленные через гомографию, выборка val




Рисунок 3.7 – Траектории, восстановленные через Essential Matrix, выборка val

На длинном маршруте train картина меняется на обратную. Расчётные пути обеих моделей сворачиваются петлями и теряют связь с эталоном уже на первой трети маршрута, однако через Essential Matrix разброс между связками заметно шире. Ни одна из них не удерживает направление до конца, а расхождение в конечной точке доходит до половины пройденного пути.




Рисунок 3.8 – Траектории, восстановленные через гомографию, выборка train




Рисунок 3.9 – Траектории, восстановленные через Essential Matrix, выборка train

Ошибка поворота накапливается иначе. Неверный поворот разворачивает все последующие шаги, но повороты в разные стороны гасят друг друга, и к концу их накапливается меньше, чем сумма ошибок всех шагов. К концу маршрута расхождение ориентации с эталонной составляет от 126,7 до 163,7 градуса независимо от модели и выборки. Иными словами, ориентация носителя теряется полностью.

3.5 Нагрузка на устройство инференса (е)

Последнее, что требуется измерить, это вычислительная стоимость. Замеры выполнялись в отдельных процессах, по одному на связку и режим, чтобы разовые затраты на загрузку библиотек и весов не приписывались той связке, которая запустилась первой. Каждый замер повторялся трижды, и за результат принималось наименьшее из трёх значений. Результаты приведены в таблице 3.6.

Таблица 3.6 – Время обработки пары кадров и расход памяти

Связка	Все потоки, мс		Один поток, мс		Память, МБ
	train	val	train	val	
SIFT + дескрипторы	59,4	67,8	98,5	152,9	600
ORB + дескрипторы	12,9	18,1	21,0	27,6	690
SIFT + оптический поток	36,1	43,7	70,0	113,1	600
ORB + оптический поток	14,2	18,6	40,1	51,1	690
SuperPoint + LightGlue	300,3	328,1	300,8	331,2	1210

Расход памяти на двух выборках совпал, поэтому приведён одной колонкой. Быстрее всех работает ORB, обе связки с ним укладываются в 13–19 миллисекунд на пару кадров. SIFT работает втрое медленнее, а SuperPoint с LightGlue примерно в двадцать раз. По памяти разрыв меньше, но той же направленности. Классические связки занимают от 600 до 700 МБ, нейросетевая около 1200 МБ, и дополнительно расходует 577 МБ видеопамяти.

Сравнение двух режимов показывает, какая часть скорости достигается за счёт многопоточности. Классические связки на всех двенадцати потоках работают в 1,5–2,8 раза быстрее, чем на одном, то есть заметная доля их скорости достигается распараллеливанием. У нейросетевой связки режимы неразличимы, поскольку основную работу выполняет видеокарта. Соотношение показано на рисунке 3.10.




Рисунок 3.10 – Влияние числа потоков процессора на время обработки пары кадров, выборка val

Само по себе время обработки мало что говорит, пока его не с чем сравнить. Естественной мерой служит скорость поступления кадров. Если расчёт успевает за съёмкой, положение носителя известно в любой момент полёта, если не успевает, оно определяется лишь задним числом.

Камера снимает 20 кадров в секунду, а обрабатывается каждый двенадцатый, то есть на вход поступает 1,7 пары в секунду. Все связки укладываются в этот темп с запасом, а значит, способны работать в реальном времени. ORB опережает съёмку более чем в тридцать раз, SIFT примерно в девять, SuperPoint с LightGlue менее чем вдвое, причём последнее значение получено на видеокарте без тензорных ядер и на более современном оборудовании было бы выше.

4 ОБСУЖДЕНИЕ

4.1 Основные наблюдения

Две меры качества, применённые к одним и тем же расчётам, дали противоположные ответы. По ошибке на паре кадров Essential Matrix опережает гомографию, по дрейфу на длинном маршруте уступает ей.

Причина в том, что ошибки этих моделей разной природы. У Essential Matrix есть постоянная часть, направленная всегда в одну сторону, и она от шага к шагу складывается. У гомографии постоянной части почти нет, а случайные отклонения разных знаков взаимно уничтожаются. Чем длиннее путь, тем сильнее сказывается это различие.

Ограничение задаёт сама съёмка. Камера покачивается вместе с носителем, а её наклон смещает изображение почти так же, как перемещение, и по двум кадрам одно от другого не отличить. Отсюда предел точности около полутора градусов, общий для всех подходов. По той же причине не восстановился и поворот носителя.

Условия съёмки при этом благоприятствуют гомографии. Наблюдаемая местность близка к плоской, а именно на плоскую сцену эта модель и рассчитана. На пересечённом рельефе соотношение между моделями могло бы оказаться иным.

Все расчёты выполнены с классическим RANSAC, перебор способов отбраковки в разделе 3.2 показал, что USAC_MAGSAC при том же времени точнее в два раза для Essential Matrix и на пятую часть для гомографии. При лучших настройках приведённые в работе ошибки были бы меньше.

Длина пути, вычисленная через гомографию, совпадает с истинной только на коротком маршруте. На длинном она систематически превышает эталонную, и полёт там проходил на большей высоте. При калибровке проявилось то же самое. Фокусное расстояние, измеренное по кадрам, росло с высотой полёта, хотя должно быть постоянным. Причина расхождения осталась невыясненной.

Заключение

В ходе исследования реализованы и сравнены три подхода к оценке собственного движения по последовательности аэрофотоснимков. Измерены устойчивость ключевых точек, качество сопоставления, характер геометрической ошибки, её накопление вдоль маршрута и вычислительная нагрузка.

Сравнение показало, что судить о методе по одному шагу нельзя. Ошибка Essential Matrix на паре кадров вдвое меньше, но содержит постоянную составляющую, которая накапливается вдоль всего пути. Ошибка гомографии больше, однако случайна и потому растёт медленнее. Чем длиннее маршрут, тем меньше значит точность отдельного шага.

Ни один из подходов не опустился ниже 1,5 градуса ошибки направления. Порог создаёт не сопоставление кадров, а сама съёмка. Камера качается вместе с вертолётom, и по двум снимкам её наклон не отличить от перемещения. Поворот носителя по той же причине восстановить не удалось.

Главный вывод в том, что ни один из рассмотренных подходов не годится для самостоятельного определения положения на протяжённом маршруте. К концу 28,5 километра расчётный путь расходится с истинным на четверть и более, а ориентация теряется полностью. Визуальная одометрия даёт грубую оценку перемещения между близкими кадрами, но удерживать положение вдоль всего полёта без внешней привязки не способна.

Наиболее очевидное продолжение работы состоит в том, чтобы дополнить одометрию внешней корректировкой. Использованный датасет создавался именно для распознавания места и содержит снимки той же местности, снятые заранее, так что сопоставление с ними, возможно, позволило бы время от времени уточнять положение и обнулять накопленную ошибку. Второе направление проще и состоит в компенсации наклона камеры, так как отбор пар по наименьшему наклону снижал ошибку в разы уже при калибровке.

Список используемых источников

1. Hartley R. Multiple View Geometry in Computer Vision / R. Hartley, A. Zisserman. 2nd ed. Cambridge: Cambridge University Press, 2004. 655 p.
2. Lowe D. G. Distinctive Image Features from Scale-Invariant Keypoints / D. G. Lowe // International Journal of Computer Vision. 2004. Vol. 60, no. 2. P. 91–110.
3. ORB: An Efficient Alternative to SIFT or SURF / E. Rublee, V. Rabaud, K. Konolige, G. Bradski // IEEE International Conference on Computer Vision. 2011. P. 2564–2571.
4. DeTone D. SuperPoint: Self-Supervised Interest Point Detection and Description / D. DeTone, T. Malisiewicz, A. Rabinovich // IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2018. P. 224–236.
5. Lucas B. D. An Iterative Image Registration Technique with an Application to Stereo Vision / B. D. Lucas, T. Kanade // Proceedings of the International Joint Conference on Artificial Intelligence. 1981. P. 674–679.
6. LightGlue: Local Feature Matching at Light Speed / P. Lindenberger, P.-E. Sarlin, M. Pollefeys // IEEE International Conference on Computer Vision. 2023. P. 17627–17638.
7. Fischler M. A. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography / M. A. Fischler, R. C. Bolles // Communications of the ACM. 1981. Vol. 24, no. 6. P. 381–395.
8. OpenCV [Электронный ресурс]: официальная документация библиотеки компьютерного зрения. URL: <https://docs.opencv.org> (дата обращения: 11.08.2026).
9. PyTorch [Электронный ресурс]: официальная документация библиотеки машинного обучения. URL: <https://pytorch.org/docs> (дата обращения: 11.08.2026).
10. ALTO: A Large-Scale Dataset for UAV Visual Place Recognition and

- Localization [Электронный ресурс]: препринт статьи I. Cisneros, P. Yin, J. Zhang, H. Choset, S. Scherer на портале arXiv. URL: <https://arxiv.org/abs/2207.12317> (дата обращения: 14.08.2026).
11. General Place Recognition: Visual Terrain Relative Navigation [Электронный ресурс]: страница соревнования ICRA 2022 на платформе AICrowd. URL: <https://www.aicrowd.com/challenges/icra2022-general-place-recognition-visual-terrain-relative-navigation> (дата обращения: 14.08.2026).
12. MAGSAC++, a Fast, Reliable and Accurate Robust Estimator / D. Barath, J. Noskova, M. Ivashechkin, J. Matas // IEEE Conference on Computer Vision and Pattern Recognition. 2020. P. 1304–1312.